

1o LISTA DE EXERCÍCIOS - CAP 5

Para obter arquivos de dados, visite:

https://github.com/jermwatt/machine_learning_refined

CAP 5

- 1) Considere a regressão linear com $N=1$, ou seja, determinar a melhor reta, no sentido de mínimos quadrados, que aproxima um conjunto de pontos no plano. Mais especificamente, dados um conjunto de pontos no plano $D = \{ (x_i, y_i) , i = 1, 2, \dots, n \}$ onde $x[i]$ e $y[i]$ representam os vetores de pontos, buscamos determinar a e b de forma a minimizar o valor de

$$\sum_{i=1}^n (ax[i] + b - y[i])^2$$

- a) Reescreva o problema acima, na formulação

$$\min_x \| Ax - c \|_2$$

Onde A é a matriz $n \times 2$ e c o vetor dimensão n .

- b) Aplique a equação normal ao problema de mínimos quadrados para verificar que este problema corresponde a resolver o sistema 2x2 abaixo:

$$\begin{bmatrix} \sum_{i=1}^n x[i]^2 & \sum_{i=1}^n x[i] \\ \sum_{i=1}^n x[i] & n \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x[i] \cdot y[i] \\ \sum_{i=1}^n y[i] \end{bmatrix}$$

- 2) Considere

$$A = \begin{pmatrix} 1 & -1 \\ 2 & 1 \\ 2 & 1 \\ -2 & 1 \end{pmatrix} \text{ e } b = \begin{pmatrix} 3 \\ -3 \\ -3 \\ -3 \end{pmatrix}$$

Calcule $\min \| Ax - b \|_2$ usando equações normais.

3) Usando a definição de convexidade [Bortolossi, 2002]:

Definição 11.6 (FUNÇÕES CONVEXAS E CÔNCAVAS)

(a) Dizemos que uma função $f: D \subset \mathbb{R} \rightarrow \mathbb{R}$ é *convexa* (ou *côncava para cima*) em um intervalo $I \subset D$ se, e somente se,

$$f((1-t) \cdot p + t \cdot q) \leq (1-t) \cdot f(p) + t \cdot f(q), \quad (11.3)$$

para todo $p, q \in I$ e todo $t \in [0, 1]$.

Verifique que $f: \mathbb{R} \rightarrow \mathbb{R}$ definida por $f(x) = x^2$ é uma função convexa.

4) Usando o teorema abaixo [Bortolossi 2002]:

Teorema 11.14 Seja $f: U \subset \mathbb{R}^n \rightarrow \mathbb{R}$ uma função de classe C^2 definida em um subconjunto convexo e aberto U de \mathbb{R}^n .

(a) f é uma função convexa em U se, e somente se, a matriz hessiana $D^2f(\mathbf{p})$ é positiva semidefinida para todo $\mathbf{p} \in U$.

(b) f é uma função côncava em U se, e somente se, a matriz hessiana $D^2f(\mathbf{p})$ é negativa semidefinida para todo $\mathbf{p} \in U$.

Verifique se as funções abaixo são convexas:

a) $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, definida por $f(x,y) = x^2 + y^2$

b) $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, definida por $f(x,y) = x^4 + y^4$

c) $f: \mathbb{R}^2 \rightarrow \mathbb{R}$, definida por $f(x,y) = x^2 + xy$

5) Visualize os gráficos das funções do exercício 4, usando o código:

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def f(x,y):
5     return x*x-x*y
6
7 x = np.linspace(-8,8,30)
8 y = np.linspace(-8,8,30)
9
10 X,Y = np.meshgrid(x,y)
11 Z = f(X,Y)
12 fig = plt.figure()
13 ax = plt.axes(projection='3d')
14 #ax.plot_wireframe(X, Y, Z, color='black')
15 ax.plot_surface(X, Y, Z, rstride=1, cstride=1,
16                 cmap='viridis', edgecolor='none')
```

6) Partindo dos dados no arquivo 3d_linregress_data.csv conforme abaixo:

```
# load in data
csvname = datapath + '3d_linregress_data.csv'
data = np.loadtxt(csvname, delimiter=',')
x = data[:-1, :]
y = data[-1, :]

print(np.shape(x))
print(np.shape(y))
```

- a) Faça a regressão $y = w_0 + x_1 w_1 + x_2 w_2$ determinando w_0 , w_1 e w_2 .
- b) Exiba o valor de da função custo obtido após a otimização.
- c) Calcule o MSE e MAD.

7) Resolver os exercícios 5.2, 5.6, 5.8, 5.11

Exercícios a serem entregues: 1) ,3) ,6) e 7) apenas o 5.8

Entrega da Lista: 11/Setembro